Навчання > Master of Science: Artificial Intelligence and Machine Learni... > Data Engineering 2.0 ВП

- ✓ Огляд дисципліни
- ✓ Тема 1. Вступ до Data Engineering
- ✓ Тема 2. Основи сховищ даних (DWH) та моделювання
- ✓ Тема 3. Apache Spark. Основи і синтаксис
- ✓ Тема 4. Apache Spark. Оптимізація та SparkUI
- ✓ Тема 5. Apache Kafka
- ✓ Наукова публікація 1
- ✓ **Тема 6. Spark streaming**
  - 👓 Навчання
    - ✓ Вступ
    - ✓ Spark Structured Streaming: концепція та мікробатчинг
    - ✓ Розбиття та на мікро-батчі. Типи тригерів
    - ✓ Output modes
    - ✓ Windows
    - ✓ Watermarks
    - ✓ Stream-Static та Stream-Stream Joins
    - ✓ Fault Tolerance та Checkpointing: як Spark гарантує коректність
    - ✓ Streaming from CSV file
    - ✓ Spark Streaming + Kafka
    - ✓ Production-стрімінг у хмарі: огляд сучасних керованих сервісів
    - — Підсумки
  - 📁 Матеріали
  - 📺 Уроки
  - 💻 **Домашнє завдання**
- ✓ Тема 7. Apache Airflow
- ✓ Тема 8. Multi-hop datalake in Databricks
- ✓ Наукова публікація 2
- ✓ Тема 9. Огляд Data Engineering Tools. Частина 1
- ✓ Тема 10. Огляд Data Engineering Tools. Частина 2
- ✓ Тема 11. Підготовка до фінального проєкту. Лекція
- ✓ Фінальне тестування

Домашнє завдання до теми «Spark streaming»

Вітаємо! Як настрій? Сподіваємось, що ви з нетерпінням очікуєте на новий челендж 😉

Ласкаво просимо до домашнього завдання, виконавши яке, ви зможете вдосконалити свої навички практичного застосування Apache Kafka.

Завдання є схожим на те, що було в попередній темі, але набагато цікавіше! 😊
Сьогодні ви будете виконувати типове завдання для моніторингу значень даних IoT приладів.

У цьому домашньому завданні вам необхідно для потоку даних з Kafka-топіку, що генерується сенсорами, **створити програму, що буде аналізувати дані та записувати алерти в alert-Kafka-топік** за виконання певних умов.

> 👓 **Алерт** — від англійського слова *alert* — тривога. Дані, що виходять за межі допустимих значень, називаються алертами. Наприклад, коли температура чи вологість виходять за допустимі значення.

Покрокова інструкція виконання

1. Генерація потоку даних:
Вхідні дані — це дані з Kafka-топіку, такі самі, як і в попередньому домашньому завданні. Згенеруйте потік даних, що містить `id`, `temperature` , `humidity`, `timestamp` . Можна використати раніше написаний вами скрипт та топік.

2. Агрегація даних:
Зчитайте потік даних, що ви згенерували в першому пункті. За допомогою *Sliding window*, що має довжину 1 хвилину, *sliding_interval* — 30 секунд, та *watermark duration* — 10 секунд, знайдіть середню температуру та вологість.

3. Знайомство з параметрами алертів:
Ваш начальник любить змінювати критерії алертів. Тому, щоб деплоїти код кожного разу, параметри алертів вказані в файлі:
alerts_conditions.csv
Файл містить максимальні та мінімальні значення для температури й вологості, повідомлення та код алерту. Значення `-999,-999` вказують, що вони не використовується для цього алерту.
Подивіться на дані в файлі. Вони мають бути інтуїтивно зрозумілі. Ви маєте зчитати дані з файлу та використати для налаштування алертів.

4. Побудова визначення алертів:
Після того, як ви знайшли середні значення, необхідно встановити, чи підпадають вони під критерії у файлі (підказка: виконайте cross join та фільтрацію).

5. Запис даних у Kafka-топік:
Отримані алерти запишіть у вихідний Kafka-топік.
Приклад повідомлення в Kafka, що є результатом роботи цього коду:

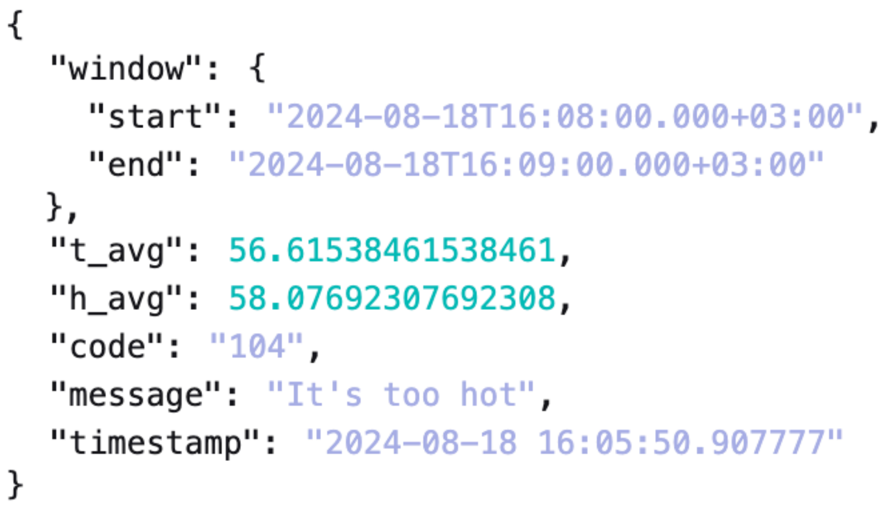

```
{
  "window": {
    "start": "2024-08-18T16:08:00.000+03:00",
    "end": "2024-08-18T16:09:00.000+03:00"
  },
  "t_avg": 56.61538461538461,
  "h_avg": 58.07692307692308,
  "code": "104",
  "message": "It's too hot",
  "timestamp": "2024-08-18 16:05:50.907777"
}
```

Критерії прийняття та оцінювання ДЗ

> ☝️ **Критерії прийняття домашнього завдання є обов’язковою умовою розгляду домашнього завдання ментором. Якщо якийсь з критеріїв не виконано, ДЗ відправляється ментором на доопрацювання без оцінювання.** Якщо вам «тільки уточнити» 😉 або ви «застопорилися» на якомусь з етапів виконання — звертайтеся до ментора у Slack).

1. Генерація даних сенсорів.
2. Знаходження середніх значень показників.
3. Побудова фільтраційного механізму, що визначить, які записи є алертами.
4. Запис даних у Kafka-топік.

Формат оцінювання — залік/незалік.
Студент отримує оцінку «залік» за умов виконання всіх вищезазначених критеріїв прийняття на базовому рівні.

Підготовка та завантаження домашнього завдання

1. Створіть публічний репозиторій `goit-de-hw-06` .
2. Виконайте завдання та відправте у свій репозиторій скриншоти виконання для **кожного з етапів** у текстовому документі з коротким описом виконання завдання.
Перелік необхідних скриншотів:
    - скрин генерації даних сенсорів та відправки даних в `building_sensors` з демонстрацією двох (або більше) одночасних роботи двох запусків програми;
    - скрин з демонстрацією того, що відфільтровані дані були послані у відповідні топіки.
3. Створіть один архів, що містить **весь** код виконання завдання, та та текстовий документ із скриншотами, прикріпіть його в LMS. Назва архіву повинна бути у форматі ДЗ6_*ПІБ*.
4. Прикріпіть посилання на репозиторій `goit-de-hw-06` та відправте на перевірку.

Формат здачі

- Посилання на репозиторій `goit-de-hw-06` .
- Прикріплений архів із назвою ДЗ6_*ПІБ.*

Завдання очікує виконання

Дедлайн 23:45, 8 листоп.

Здай домашнє завдання!

Завантаж сюди посилання на домашнє завдання

Завантаж файл до 150 Мб

Відправити домашнє завдання